

Grammatiche libere dal contesto

Sia $G = (V, T, P, S)$ una CFG. Un albero e' un **albero sintattico** per G se:

- 1 Ogni nodo interno e' etichettato con una variabile in V .
- 2 Ogni foglia e' etichettata con un simbolo in $V \cup T \cup \{\epsilon\}$.
Ogni foglia etichettata con ϵ e' l'unico figlio del suo genitore.
- 3 Se un nodo interno e' etichettato A , e i suoi figli (da sinistra a destra) sono etichettati


$$X_1, X_2, \dots, X_k,$$

allora $A \rightarrow X_1 X_2 \dots X_k \in P$.

Nella grammatica

1. $E \rightarrow a$
2. $E \rightarrow E + E$
3. $E \rightarrow E * E$
4. $E \rightarrow (E)$

il seguente e' un albero sintattico:




Questo albero sintattico mostra la derivazione $E \xrightarrow{*} a + E$

Nella grammatica

1. $P \rightarrow \epsilon$
2. $P \rightarrow 0$
3. $P \rightarrow 1$
4. $P \rightarrow 0P0$
5. $P \rightarrow 1P1$

il seguente e' un albero sintattico:



Mostra la derivazione $P \xrightarrow{*} 0110$.


Il prodotto di un albero sintattico

- Il **prodotto** di un albero sintattico e' la stringa di foglie da sinistra a destra.
- Sono importanti quegli alberi sintattici dove:
 - ① Il prodotto e' una stringa terminale.
 - ② La radice e' etichettata dal simbolo iniziale.
- L'insieme dei prodotti, formati da soli terminali, di questi alberi sintattici e' il linguaggio della grammatica.

Estendiamo la grammatica delle espressioni per arricchire il linguaggio degli identificatri.

Consideriamo la grammatica $G = (\{E, I\}, T, P, E)$ dove $T = \{+, *, (,), a, b, 0, 1\}$ e P e' il seguente insieme di produzioni:

1. $E \rightarrow I$
2. $E \rightarrow E + E$
3. $E \rightarrow E * E$
4. $E \rightarrow (E)$
5. $I \rightarrow a$
6. $I \rightarrow b$
7. $I \rightarrow Ia$
8. $I \rightarrow Ib$
9. $I \rightarrow I0$
10. $I \rightarrow I1$





Il prodotto e' $a * (a + b00)$.

Sia $G = (V, T, P, S)$ una CFG, e $A \in V$. I seguenti sono equivalenti:

- 1 $A \xrightarrow{*} w$
- 2 $A \xrightarrow[lm]{*} w$, e $A \xrightarrow[rm]{*} w$
- 3 C'è un albero sintattico di G con radice A e' prodotto w .


Alberi sintattici e Forme sentenziali



In particolare ad *ogni frontiera interna* di un albero sintattico corrisponde una forma sentenziale. Le frontiere interne in blu corrispondono rispettivamente alle forme sentenziali $0P0$ e $I^*(E)$.

Alberi sintattici e Derivazioni leftmost

Consideriamo l'albero:



Si puo' costruire una *derivazione sinistra* corrispondente
 espendendo le variabili secondo la lettura in preordine dei nodi
 dell'albero. Iniziamo con $E \xrightarrow{lm} E * E$ e espandiamo
 succesivamente la prima E in I e cosi' via:

$$\begin{aligned}
 E &\xrightarrow{lm} E * E \xrightarrow{lm} \\
 I * E &\xrightarrow{lm} a * E \xrightarrow{lm} \\
 a * (E) &\xrightarrow{lm} a * (E + E) \xrightarrow{lm} \\
 a * (I + E) &\xrightarrow{lm} a * (a + E) \xrightarrow{lm} \\
 a * (a + I) &\xrightarrow{lm} a * (a + I0) \xrightarrow{lm} \\
 a * (a + I00) &\xrightarrow{lm} a * (a + b00)
 \end{aligned}$$

C'e una *corrispondenza biunivoca* tra alberi sintattici e derivazioni
leftmost.

Alberi sintattici e Derivazioni rightmost

Allo stesso modo da un albero sintattico si puo' costruire una derivazione *destra* corrispondente espendendo le variabili in ordine inverso.

Per lo stesso albero sintattico si ottiene:

$$\begin{aligned} E &\xrightarrow{rm} E * E \xrightarrow{rm} \\ E * (E) &\xrightarrow{rm} E * (E + E) \xrightarrow{rm} \\ E * (E + I) &\xrightarrow{rm} E * (E + I0) \xrightarrow{rm} \\ E * (E + I00) &\xrightarrow{rm} E * (E + b00) \xrightarrow{rm} \\ E * (I + b00) &\xrightarrow{rm} E * (a + b00) \xrightarrow{rm} \\ I * (a + b00) &\xrightarrow{rm} a * (a + b00) \end{aligned}$$

C'e una *corrispondenza biunivoca* anche tre alberi sintattici e derivazioni *rightmost*.

Ambiguità in Grammatiche e Linguaggi

Nella grammatica

1. $E \rightarrow I$
2. $E \rightarrow E + E$
3. $E \rightarrow E * E$
4. $E \rightarrow (E)$
- ...



la forma sentenziale $E + E * E$ ha due derivazioni:

$$E \rightarrow E + E \rightarrow E + E * E$$

e

$$E \rightarrow E * E \rightarrow E + E * E$$


Questo ci dà due alberi sintattici:




Definizione: Sia $G = (V, T, P, S)$ una CFG. Diciamo che G e' **ambigua** se esiste una stringa in T^* che ha piu' di un albero sintattico.

Se ogni stringa in $L(G)$ ha al piu' un albero sintattico, G e' detta **non ambigua**.

Esempio: La stringa terminale $a + a * a$ ha due alberi sintattici:



(a)



(b)

L'esistenza di **varie derivazioni** di per se non e' pericolosa, e'
l'esistenza di **vari alberi sintattici** che rovina la grammatica.
Esempio: Nella stessa grammatica la stringa $a + b$ ha varie
derivazioni:

$$E \rightarrow E + E \rightarrow I + E \rightarrow a + E \rightarrow a + I \rightarrow a + b$$

e

$$E \rightarrow E + E \rightarrow E + I \rightarrow I + I \rightarrow I + b \rightarrow a + b$$

Pero' il loro albero sintattico e' lo stesso, e la struttura di $a + b$ e'
quindi non ambigua.

Ma per dire che una grammatica e' ambigua basta che ci sia
anche solo una (o piu') stringa con due alberi di derivazione
diversi. Come quella della slide precedente (e molte altre in
questo caso).

Rimuovere l'ambiguità' dalle grammatiche

- Buone notizie: a volte possiamo rimuovere l'ambiguità'
- Cattive notizie: non c'è nessun algoritmo per farlo in modo sistematico
- Ancora cattive notizie: alcuni CFL hanno solo CFG ambigue
- Studiamo la grammatica

$$E \rightarrow I \mid E + E \mid E * E \mid (E)$$

$$I \rightarrow a \mid b \mid Ia \mid Ib \mid I0 \mid I1$$

- Non c'è precedenza tra $*$ e $+$
- Non c'è raggruppamento di sequenze di operatori: $E + E + E$ è inteso come $E + (E + E)$ o come $(E + E) + E$?


Soluzione: Introduciamo piu' variabili, ognuna che rappresenta espressioni con lo stesso grado di "forza di legamento"

- ① Un *fattore* e' un'espressione che non puo' essere spezzata da un $*$ o un $+$ adiacente. I nostri fattori sono:
 - ① Identificatori
 - ② Un'espressione racchiusa tra parentesi.
- ② Un *termine* e' un'espressione che non puo' essere spezzata da un $+$. Ad esempio, $a * b$ non puo' essere spezzata da $+$, perche' ad esempio $a1 + a * b$ e' (secondo le regole di precedenza) lo stesso di $a1 + (a * b)$, e $a * b + a1$ e' lo stesso di $(a * b) + a1$.
- ③ Il resto sono *espressioni*, cioe' possono essere spezzate con $*$ o $+$.

Usiamo F per i fattori, T per i termini, e E per le espressioni.
Consideriamo la seguente grammatica:

1. $I \rightarrow a \mid b \mid Ia \mid Ib \mid I0 \mid I1$
2. $F \rightarrow I \mid (E)$
3. $T \rightarrow F \mid T * F$
4. $E \rightarrow T \mid E + T$

Ora l'unico albero sintattico per $a + a * a$ e':



Perche' la nuova grammatica non e' ambigua?

- Un fattore e' o un identificatore o (E) , per qualche espressione E .
- L'unico albero sintattico per una sequenza


$$f_1 * f_2 * \cdots * f_{n-1} * f_n$$

di fattori e' quello che da' $f_1 * f_2 * \cdots * f_{n-1}$ come termine e f_n come fattore, come nell'albero del prossimo lucido.

- Un'espressione e' una sequenza


$$t_1 + t_2 + \cdots + t_{n-1} + t_n$$

di termini t_i . Puo' essere solo raggruppata con $t_1 + t_2 + \cdots + t_{n-1}$ come un'espressione e t_n come un termine.




Derivazioni a sinistra e ambiguità'

I due alberi sintattici per $a + a * a$



(a)



(b)

danno luogo a due derivazioni:

$$\begin{aligned} E &\xrightarrow{lm} E + E \xrightarrow{lm} I + E \xrightarrow{lm} a + E \xrightarrow{lm} a + E * E \\ &\xrightarrow{lm} a + I * E \xrightarrow{lm} a + a * E \xrightarrow{lm} a + a * I \xrightarrow{lm} a + a * a \end{aligned}$$

e

$$E \xrightarrow{lm} E * E \xrightarrow{lm} E + E * E \xrightarrow{lm} I + E * E \xrightarrow{lm} a + E * E \dots$$

In generale:

- Un albero sintattico, ma molte derivazioni
- Molte derivazioni **a sinistra** implica molti alberi sintattici.
- Molte derivazioni **a destra** implica molti alberi sintattici.

Teorema 5.29: Data una CFG G , una stringa terminale w ha due distinti alberi sintattici se e solo se w ha due distinte derivazioni a sinistra dal simbolo iniziale.

Prova:

- (*Solo se.*) Se due alberi sintattici sono diversi, hanno un nodo dove sono state usate due diverse produzioni:
 $A \rightarrow X_1 X_2 \cdots X_k$ e $B \rightarrow Y_1 Y_2 \cdots Y_m$. Le corrispondenti derivazioni a sinistra useranno queste diverse produzioni e quindi saranno distinte.
- (*Se.*) Per come costruiamo un albero da una derivazione, e' chiaro che due derivazioni distinte generano due alberi distinti.

Un CFL L è **inerentemente ambiguo** se **tutte** le grammatiche per L sono ambigue.

Esempio: Consideriamo $L =$

$$\{a^n b^n c^m d^m : n \geq 1, m \geq 1\} \cup \{a^n b^m c^m d^n : n \geq 1, m \geq 1\}.$$

Una grammatica per L è

$$S \rightarrow AB \mid C$$


$$A \rightarrow aAb \mid ab$$

$$B \rightarrow cBd \mid cd$$

$$C \rightarrow aCd \mid aDd$$

$$D \rightarrow bDc \mid bc$$

Guardiamo la struttura sintattica della stringa $aabbccdd$.



Vediamo che ci sono due derivazioni a sinistra:

$$S \xrightarrow{lm} AB \xrightarrow{lm} aAbB \xrightarrow{lm} aabbB \xrightarrow{lm} aabbcBd \xrightarrow{lm} aabbccdd$$

e


$$S \xrightarrow{lm} C \xrightarrow{lm} aCd \xrightarrow{lm} aaDdd \xrightarrow{lm} aabDcdd \xrightarrow{lm} aabbccdd$$

Puo' essere provato che **ogni** grammatica per L si comporta come questa. Il linguaggio L e' quindi inerentemente ambiguo.

- Un linguaggio regolare e' anche libero da contesto.
- Da una espressione regolare, o da un automa, si puo' ottenere una grammatica che genera lo stesso linguaggio.

- Un simbolo non-terminale per ogni stato.
- Simbolo iniziale = stato iniziale.
- Per ogni transizione da stato s a stato p con simbolo a , produzione $S \rightarrow aP$.
- Se p stato finale, allora produzione $P \rightarrow \epsilon$

Automa:



Grammatica:

$$Q_0 \rightarrow 1Q_0 \mid 0Q_2$$

$$Q_2 \rightarrow 0Q_2 \mid 1Q_1$$

$$Q_1 \rightarrow 0Q_1 \mid 1Q_1 \mid \epsilon$$

La stringa 1101 e' accettata dall'automa. Nella grammatica, ha la derivazione:

$$Q_0 \rightarrow 1Q_0 \rightarrow 11Q_0 \rightarrow 110Q_2 \rightarrow 1101Q_1 \rightarrow 1101$$